





GENERATIVE MODELS FOR VIDEO PREDICTION

Robotics course, MSc in Computer Science Artificial Intelligence

Tutor:
Dr. Enrico Donato



Presentato da:
Gabriele Di Giulio

OLTRE LA PERCEZIONE

PERCHÈ CI INTERESSA IL FUTURO

Prevedere il futuro a lungo termine trasforma il robot da reattivo a un'entità proattiva.

La necessità fondamentale è l'anticipazione.

1. Pianificazione basata sull'Immaginazione
2. Superare il ritardo dei sensori
3. Comprensione della Causalità
4. Sicurezza intrinseca

WORLD MODEL

Un World Model è un sistema computazionale in grado di apprendere una rappresentazione interna della realtà e di simulare autonomamente la fisica e la dinamica dell'ambiente circostante.



WORLD MODEL MULTI-MODALE

PERCHÈ UN WORLD MODEL MULTIMODALE

I robot sono equipaggiati con un'ampia gamma di sensori multimodali perché ogni modalità cattura un tipo di informazione fisica e spaziale differente.

Esistono variabili fisiche che non possono essere dedotte da una singola fonte.

L'uso congiunto di più modalità percettive permette un'astrazione completa del mondo circostante.

COME FARE UN WORLD MODEL?

Tramite Deep generative AI.


In letteratura ci sono molti SOTA:

Modelli Sequenziali Autoregressivi:

- **DREAMER**
- **IRIS**

Modelli basati su Flussi e Diffusioni:

- **NANO WM**
- **OPEN SORA**



IL NOSTRO OBIETTIVO

Obbiettivo del progetto: sviluppare un framework completo per costruire world models usando differenti architetture e metodologie capaci di simulare la dinamica di un sistema robotico prevedendo la sua evoluzione visiva, tattile e propriocettiva.

Stato Multimodale al tempo t :

$$O_t = \{X_t, S_t, P_t\}$$

Vogliamo massimizzare la probabilità condizionata delle osservazioni future date le osservazioni passate e le azioni intraprese

$$P(O_{t+1:t+N} \mid O_1, \dots, O_t, A_t, \dots, A_{t+N-1})$$

Encoder: Compressione delle osservazioni ad alta dimensionalità in uno spazio compatto:

$$Z_t = [z_{img,t}, z_{tac,t}, z_{pos,t}]$$

Transizione Markoviana: Lo stato Z_t racchiude l'intera informazione del presente. Prevediamo il futuro in modo autoregressivo:


$$P(Z_{t+1} \mid Z_t, A_t)$$

Modello Dinamico: L'azione A_t viene concatenata per predire lo stato latente successivo:


$$Z_{t+1} = f_\theta(Z_t \oplus A_t)$$

Decoder: Decodifica delle grandezze fisiche per generare la previsione finale:

$$O_{t+1} = \{X_{t+1}, S_{t+1}, P_{t+1}\}$$



ARCHITETTURA GENERICA



Predizione 1-Step: La rete calcola lo stato latente imminente basandosi sul presente e sull'azione attuale.


Re-iniezione: Per simulare l'evoluzione a lungo termine (fino a N step), l'output predetto viene re-inserito nel modello come nuovo input per lo step successivo.

$$Z_{t+k} = f_{\theta}(Z_{t+k-1} \oplus A_{t+k-1})$$

Il modello immagina l'esito a lungo termine della sequenza di azioni senza aver più bisogno di leggere i sensori reali.



ARCHITETTURA CON VAE



COME FUNZIONA VAE


1. Compressione dell'Input.
2. Encoder del VAE impara a mappare i dati in una distribuzione di probabilità.
3. Reparameterization Trick (Campionamento)
4. Decoder, espansione e ricostruzione

Governato da una funzione di perdita composta da due elementi in tensione tra loro: Errore di Ricostruzione + KL

Azione t



ARCHITETTURA CON VQ VAE




COME FUNZIONA VQ VAE

1. Compressione dell'Input.
2. Quantizzazione Vettoriale (Il Codebook)
3. Il Trucco del Gradiente (Straight-Through Estimator)
4. Decoder, espansione e ricostruzione

L'addestramento del VQ-VAE si basa su tre concetti chiave:

- Errore di Ricostruzione+Commitment Loss
- Aggiornamento EMA e "Dead Codes":




DINAMICHE DI PREDIZIONE

MLP (Multi-Layer Perceptron)

Il vettore fuso attraversa una rete Feed-Forward composta da strati lineari consecutivi intervallati da funzioni di attivazione non lineari.

MLP adotta un approccio puramente deterministico significa che a: a parità di input, restituirà sempre, matematicamente, lo stesso identico output.

La rete MLP calcola quindi l'Errore Quadratico Medio (MSE) tra la sua predizione e il target reale



FLOW MATCHING

Il Flow Matching invece è un modello generativo.

Per prevedere lo stato futuro parte dal caos campionando puro rumore gaussiano.


L'obiettivo è trasformare gradualmente questo rumore nello stato corretto, lungo un asse temporale continuo.

Per orientarsi, la rete fonde in un unico input il rumore attuale, l'istante temporale, lo stato corrente e l'azione da eseguire.

La rete neurale predice esclusivamente un vettore di velocità, indicando la direzione e l'intensità della "spinta" necessaria per guidare il rumore verso la forma finale esatta.



UN FRAMEWORK COMPLETO




SPLIT DEI DATI

Trattandosi di traiettorie temporali, non è possibile applicare uno shuffle casuale globale dei dati.

Ciascun trial viene diviso prima cronologicamente in tre blocchi consecutivi:

- 70% Training
- 15% Validation
- 15% Testing

Solo dopo aver effettuato lo split temporale su ogni singolo trial, uniamo tra loro i rispettivi blocchi.



TRAINING A DUE FASI

Fase 1: Si allena l'architettura encoder/decoder (VAE o VQ-VAE) a ricostruire perfettamente le modalità sensoriali. I modelli di dinamica sono spenti.

Terminata la Fase 1, si congelano i pesi degli encoder e dei decoder.

Fase 2: Con lo spazio latente ormai stabilizzato, si addestra esclusivamente il modello di dinamica

Funzioni di Loss della Fase 1

L'obiettivo è la fedeltà di ricostruzione dello stato corrente. La loss cambia a seconda del tipo di spazio latente scelto:

Se si usa **VAE**:

$$\mathcal{L}_{VAE} = \text{MSE}_{\text{Ricostruzione}} + \beta \cdot \text{KL Divergence}$$


Se si usa **VQ VAE**:

$$\mathcal{L}_{VQ-VAE} = \text{MSE}_{\text{Ricostruzione}} + \beta \cdot \mathcal{L}_{\text{Commitment}}$$

Funzioni di Loss della Fase 2

L'obiettivo di questa fase è la precisione temporale sul "Next-State". La loss misura la capacità del modello di mappare la transizione temporale, ma l'oggetto della misura si adatta alla dinamica scelta:

$$\mathcal{L}_{\text{Dynamics}} = \text{MSE}(\text{Target}, \text{Predizione})$$



VALIDATION E EARLY STOPPING

Alla fine di ogni epoca di training, il modello viene valutato sul Validation Set (15% dei dati).

Patience: Monitoriamo costantemente la Validation Loss, se questa non migliora per n epoche consecutive, l'addestramento viene interrotto (Early Stop).

Min Delta: Per evitare che variazioni microscopiche contino come un miglioramento.

Viene salvato il modello che ha raggiunto la Validation Loss minima assoluta




VALUTAZIONE DEI MODELLI DI RICOSTRUZIONE

Misurare la fedeltà del modello nel comprimere e decomprimere i dati sensoriali.

Calcoliamo il Mean Squared Error tra l'input sensoriale reale (visione, tatto, propriocezione) e la sua ricostruzione decompressa dal decoder.

Un'ottima ricostruzione indica semplicemente che il Decoder è in grado di decodificare i punti memorizzati dall'Encoder.

Tuttavia, se lo spazio latente non possiede una struttura geometrica liscia, coerente e allineata con la causalità temporale delle azioni, il modello di Predizione non sarà in grado di tracciare traiettorie stabili.



VALUTAZIONE DEI MODELLI DI PREDIZIONE

I modelli generativi introducono elementi stocastici durante l'inferenza.

Lo script non esegue il test una sola volta per ogni predizione (sia 1-step che rollout), il modello genera 3 sample indipendenti

L'errore finale è calcolato come la media di questi campionamenti.

Il modello è valutato su due task:

- 1-step prediction
- Rollout autoregressivo da 50 step


Predizione a 1-Step: Misurare la precisione immediata del World Model sul singolo step temporale.

Rollout Autoregressivo a 50 Step mediato su 8 traiettorie equidistanti.

Mean MSE: Errore medio complessivo accumulato durante l'intero arco dei 50 step.

Final MSE: L'errore registrato esattamente al 50° step.

AUC: L'area sottesa dalla curva temporale dell'errore, errore accumulato nel tempo.



TEST E RISULTATI

PICCOLA PREMESSA

I risultati non mirano a sviluppare un modello perfetto quanto invece a testare l'architettura in modo coerente e valido.


Ciò è dovuto dalla natura dei training estremamente pesante e lunga che ha impedito un fine tuning ottimale.

Nonostante ciò sono emerse osservazioni interessanti che abbiamo analizzato.




RISULTATI RICOSTRUZIONE VAE

RICOSTRUZIONE OTTIMALE $\neq$ OTTIMO LATENT SPACE




VAE Image Recon MSE : 0.000187
VAE Tactile Recon MSE : 0.100682
VAE Proprio Recon MSE : 0.002253

VAE Proprio Recon: Trial 1 no_obj



VAE Tactile Recon: Trial 1 no_obj



Ground Truth




Ricostruzione




RISULTATI RICOSTRUZIONE VQ VAE

RICOSTRUZIONE OTTIMALE ≠ OTTIMO LATENT SPACE



VAE Image Recon MSE : 0.000171
VAE Tactile Recon MSE : 0.099821
VAE Proprio Recon MSE : 0.002289







Ground Truth






Ricostruzione



RISULTATI PREDIZIONE VAE + FLOW



RISULTATI PREDIZIONE VAE + MLP



Ground Truth

1-step

Rollout



CONFRONTO DEI RISULTATI



VAE

MODELLO	IMG 1-step MSE	TAC 1-step MSE	POS 1-step MSE	IMG Rollout MSE	IMG Rollout MSE last	IMG AUC	TAC Rollout MSE	TAC Rollout MSE last	POS Rollout MSE	POS Rollout MSE last
MLP	0.002766	0.451436	0.215339	0.004510	0.005357	0.004530	0.640090	0.553902	1.334929	1.533380
FLOW	0.003545	0.509537	0.264298	0.006334	0.006586	0.006371	0.685439	0.568657	2.859417	3.501023

Modello deterministico allenato su MSE è
una metrica affidabile?

APPROFONDENDO LE ANALISI SU MLP

**Ha imparato a essere
condizionato dalle
azioni?**



**Image SSIM
mean**

0.906976

**Image LPIPS
mean**

0.123824

**Tactile
shape error
mean**

0.260945

**Tactile traj
corr**

0.129541

**Proprio
shape error
mean**

0.071413

**Proprio traj
corr**

0.104341

**Ha imparato
effettivamente qualcosa
sulla dinamica del
mondo?**

MENTRE VQ-VAE?


Il VQ-VAE produce una rappresentazione latente discreta. L'applicazione di modelli dinamici continui come il Flow Matching o regressori come l'MLP risulta geometricamente innaturale e forzata. La discrepanza tra il latente discreto della visione e il latente continuo di tatto/propriocezione (VAE) rompe la sincronizzazione fisica del World Model.

Possibili futuri miglioramenti come l'integrazione nel framework di modelli di dinamica sequenziali autoregressivi.

FLOW



MLP



CONCLUSIONI E SVILUPPI FUTURI


Abbiamo sviluppato un'infrastruttura robusta e completa per l'intero ciclo di vita del modello: gestione dataset, addestramento disaccoppiato, validazione con early-stopping e testing rigoroso 1-step/multistep.

Il framework permette di testare e confrontare agilmente diverse configurazioni dello spazio latente e dei modelli di transizione dinamica.

Ampliamento dei modelli predittivi come: Diffusion, DiT, Transformers, Gated RNN...

Testare la capacità del World Model di effettuare una sintesi cross-modale.

GRAZIE DELL'ATTENZIONE!



APPENDICE

RISULTATI VQ-VAE

VQ VAE

MODELLO	IMG 1-step MSE	TAC 1-step MSE	POS 1-step MSE	IMG Rollout MSE	IMG Rollout MSE last	IMG AUC	TAC Rollout MSE	TAC Rollout MSE last	POS Rollout MSE	POS Rollout MSE last
MLP	0.003063	0.455659	0.234674	0.026829	0.009262	0.009154	2.222340	1.248302	434.289301	64.478652
FLOW	0.005817	0.622561	0.334611	0.008296	0.009217	0.008317	0.846985	0.685677	1.307099	1.050902

APPROFONDENDO LE ANALISI SU FLOW






Image SSIM mean	Image LPIPS mean	Tactile shape error mean	Tactile traj corr	Proprio shape error mean	Proprio traj corr
0.863352	0.143510	0.550727	0.047046	0.240523	0.005210


ALTRI RISULTATI VAE

LATENT 64,16,16


Loss Curve — Training vs Validation




VAE Tactile Recon: Trial 1 no_obj



VAE Proprio Recon: Trial 1 no_obj



VAE Image Recon MSE : 0.000243
VAE Tactile Recon MSE : 0.000392
VAE Proprio Recon MSE : 0.000487



ALTRI RISULTATI MLP

LATENT 64,16,16







Image SSIM
mean

Image LPIPS
mean

Tactile
shape error
mean

Tactile traj
corr

Proprio
shape error
mean

Proprio traj
corr

0.921977

0.118692

0.258465

0.122274

0.069038

0.258465